

Generator Sztucznych Danych Osobowych

Konspekt Projektu

Skład zespołu:

Szymon Domański, Krzysztof Dąbrowski, Gustaw Gabrylewski

Data:

06.12.2025

1 Ogólna charakterystyka i cel projektu

1.1 Charakterystyka

Projekt polega na stworzeniu aplikacji służącej do generowania dużych zbiorów syntetycznych danych osobowych (imię, nazwisko, adres, PESEL, numer dowodu, e-mail, itd.). Aplikacja pozwala na parametryzację generowanych danych (np. struktura płci, zakres wieku, region zamieszkania).

1.2 Cel projektu

Celem jest dostarczenie narzędzia dla programistów i testerów, które umożliwia szybkie tworzenie bezpiecznych (niezawierających prawdziwych danych wrażliwych) baz danych testowych, zgodnych z formatami używanymi w Polsce (np. walidacja PESEL).

1.3 Opis biznesowy

W dobie RODO testowanie aplikacji na prawdziwych danych klientów jest ryzykowne i prawnie skomplikowane. Firmy potrzebują wiarygodnych danych testowych, które zachowują spójność logiczną (np. cyfra kontrolna w numerze PESEL zgadza się z datą urodzenia), ale są całkowicie fikcyjne. Projekt rozwiązuje problem braku łatwo dostępnych, spójnych danych testowych dla rynku polskiego.

2 Założenia i Funkcje

2.1 Główne założenia

- Aplikacja działa jako narzędzie desktopowe.
- Możliwość generowania od pojedynczych rekordów do masowych ilości.
- Dane są logicznie spójne (płeć wynikająca z imienia zgadza się z numerem PESEL).

2.2 Kluczowe funkcje

1. **Konfigurator danych:** Wybór jakie pola mają być generowane (np. tylko Imię + Nazwisko, czy pełny profil z adresem i NIP).
2. **Zakres generowanych danych:** Imię, nazwisko, wiek, data urodzenia, płeć, PESEL, nr dowodu osobistego, NIP, nr domu/mieszkania, ulica, miejscowość, kod pocztowy, województwo, nr telefonu, adres e-mail, hasło.
3. **Generator danych:** Algorytmy tworzące poprawne numery z cyframi kontrolnymi (np. PESEL, NIP).
4. **Eksport danych:** Zapis wyników do popularnych formatów (CSV, JSON, XML, SQL).

3 Wymagania

3.1 Wymagania Funkcjonalne

1. System musi pozwalać na wybór liczby rekordów do wygenerowania.
2. System musi generować unikalne identyfikatory (np. PESEL) w ramach jednej paczki danych.
3. Użytkownik może zdefiniować format wyjściowy pliku (CSV/JSON/SQL).
4. System musi weryfikować poprawność sum kontrolnych dla polskich identyfikatorów.

3.2 Wymagania Niefunkcjonalne

1. **Wydajność:** Wygenerowanie 100 000 rekordów nie powinno trwać dłużej niż 15 sekund.
2. **Użyteczność:** Intuicyjny interfejs pozwalający na wygenerowanie danych w max. 3 krokach.
3. **Przenośność:** Aplikacja powinna działać na systemach Windows i Linux (dzięki Javie/Python).